LAPORAN TUGAS BESAR 1: JARINGAN SYARAF TIRUAN (IT6053)

Analisis dan Implementasi Klasifikasi Data Menggunakan Perceptron dan ADALINE

Kelompok 09 • Program Studi Informatika • Fakultas Teknologi Informasi • Universitas Kristen Duta Wacana
Anggota: Fransina Riyanty Batlayar (71231014), Amelia Agustin (71231038), Nengah Yesi Putri (71231047), Samuel Natanael (71231050)

1. MASALAH DAN TUJUAN

Program Makan Bergizi Gratis (MBG) yang diinisiasi oleh Pemerintah Indonesia merupakan salah satu kebijakan sosial dan kesehatan publik berskala masif yang memicu perdebatan intensif di ruang publik digital. Melalui platform media sosial seperti YouTube, masyarakat secara aktif menyuarakan pendapat yang beragam, mulai dari apresiasi dan rasa syukur atas peningkatan nutrisi bagi generasi muda hingga kritik mendalam mengenai transparansi pengadaan bahan makanan, risiko korupsi anggaran daerah, serta kekhawatiran atas standar higienitas. Volume komentar yang mencapai ribuan data menyebabkan evaluasi dan pemantauan opini secara manual menjadi tidak efisien dan tidak terukur.

Tujuan dari studi kasus ini adalah merumuskan permasalahan opini publik ke dalam paradigma *supervised learning* dengan membangun model klasifikasi biner berbasis neuron tunggal, yaitu **Perceptron (Rosenblatt, 1958)** dan **ADALINE (Widrow & Hoff, 1960)**. Eksperimen ini bertujuan menguji dan membandingkan karakteristik pembaruan bobot, sensitivitas laju pembelajaran (α), peranan standardisasi fitur, stabilitas konvergensi, serta keterbatasan separabilitas linear pada data opini publik riil.

2. DATASET DAN KAITANNYA DENGAN TUGAS 1

Penelitian ini melanjutkan dataset yang telah dianalisis pada **Tugas 1**, yaitu kumpulan komentar publik berbahasa Indonesia mengenai program MBG yang diekstraksi dari YouTube pada rentang Januari hingga Maret 2026. Dataset mentah terdiri dari 6.419 observasi dengan atribut metadata: `author`, `published_at`, `like_count`, `text`, dan `public`. Pada Tugas 1, data masih berupa korpus teks mentah tanpa label polaritas target numerik.

Untuk memenuhi persyaratan klasifikasi biner Tugas Besar 1, teks komentar dibersihkan melalui tahap pemrosesan awal (*case folding*, pembersihan URL, mention, tanda baca, dan angka). Selanjutnya, pelabelan sentimen biner dilakukan menggunakan pendekatan berbasis leksikon sentimen Bahasa Indonesia yang komprehensif, menghasilkan target kelas biner:

- **Kelas Positif (+1)**: Komentar yang merefleksikan dukungan, rasa syukur, manfaat kesehatan, dan optimisme terhadap program (1.045 sampel).
- **Kelas Negatif (-1)**: Komentar yang memuat keluhan, sindiran, tuduhan korupsi/kebijakan buruk, dan kekecewaan (967 sampel).

Komentar netral atau tidak bermuatan polaritas disaring, menyisakan total **2.012 sampel data valid** dengan distribusi kelas yang sangat seimbang (~52% Positif vs ~48% Negatif). Fitur input numerik utama yang digunakan adalah `pos_score` (frekuensi kata leksikon positif) dan `neg_score` (frekuensi kata leksikon negatif), yang secara semantik memetakan polaritas teks secara terukur ke dalam ruang 2D.

3. ARTIKEL ILMIAH DAN KODE PENDUKUNG

Keputusan desain eksperimen dan landasan matematis didukung oleh literatur ilmiah utama dan dokumentasi teknis berikut:

1. **Rosenblatt, F. (1958)**, *"The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain"*, Psychological Review. Artikel ini menjadi rujukan utama prinsip kerja neuron biner, fungsi ambang (*step function*), dan teorema konvergensi Perceptron pada data linear.
2. **Widrow, B., & Hoff, M. E. (1960)**, *"Adaptive Switching Circuits"*, IRE WESCON Convention Record. Paper ini mendasari implementasi ADALINE (*Adaptive Linear Neuron*) dengan aturan Delta (*Widrow-Hoff Rule* / *Least Mean Squares*), yang memperkenalkan penggunaan error kontinu sebelum fungsi ambang guna meminimalkan Mean Squared Error.
3. **Raschka, S. (2015)**, *Python Machine Learning* dan Dokumentasi Mlxtend Classifier. Menjadi acuan perancangan kode pembaruan bobot berbasis vektor NumPy, batch gradient descent, serta protokol pembagian data tanpa kebocoran (*data leakage*).

4. MODEL NEURON DAN ATURAN PEMBELAJARAN

4.1 Formulasi Neuron dan Persamaan Aktivasi

Kedua model menggunakan representasi net input linear yang sama dari vektor bobot $\mathbf{w} = [w_1, w_2]^T$, vektor fitur masukan $\mathbf{x} = [x_1, x_2]^T$, dan skalar bias b:

$$z = \mathbf{w}^T\mathbf{x} + b = w_1x_1 + w_2x_2 + b$$

Prediksi kelas akhir $\hat{y}$ ditentukan menggunakan fungsi ambang (*threshold function*):

$$\hat{y} = +1 \text{ jika } z \geq 0, \text{ dan } \hat{y} = -1 \text{ jika } z < 0$$

4.2 Perbedaan Aturan Pembaruan Parameter

Perbedaan fundamental kedua model terletak pada bagaimana error didefinisikan dan digunakan dalam pembaruan parameter:

- **Perceptron**: Menggunakan error diskrit dari keluaran fungsi tangga ($e = y - \hat{y} \in \{-2, 0, +2\}$). Pembaruan bersifat sekuensial per sampel:

  $$\Delta = \alpha(y^{(i)} - \hat{y}^{(i)})$$
  $$\mathbf{w} \leftarrow \mathbf{w} + \Delta\,\mathbf{x}^{(i)}, \quad b \leftarrow b + \Delta$$

- **ADALINE**: Menggunakan error kontinu dari net input linear ($e^{(i)} = y^{(i)} - z^{(i)}$). Pembaruan parameter dilakukan secara simultan seluruh sampel (*Batch Gradient Descent*) untuk meminimalkan fungsi Mean Squared Error (MSE):

  $$MSE = (1/n)\sum_{i=1}^{n}(y^{(i)} - z^{(i)})^2$$
  $$\mathbf{w} \leftarrow \mathbf{w} + \alpha\,(\mathbf{X}^T\mathbf{e} / n), \quad b \leftarrow b + \alpha \cdot \text{mean}(\mathbf{e})$$

5. PENYIAPAN DATA DAN RANCANGAN EKSPERIMEN

Dataset (2.012 sampel) dibagi menjadi 80% data latih (1.609 sampel) dan 20% data uji (403 sampel) secara terstratifikasi dengan `random_state = 42`. Standardisasi z-score (mean 0, variansi 1) dilakukan dengan mempelajari parameter mean dan standar deviasi **hanya dari data latih**, lalu diterapkan pada data uji untuk menjamin integritas evaluasi bebas kebocoran (*leakage-free*).

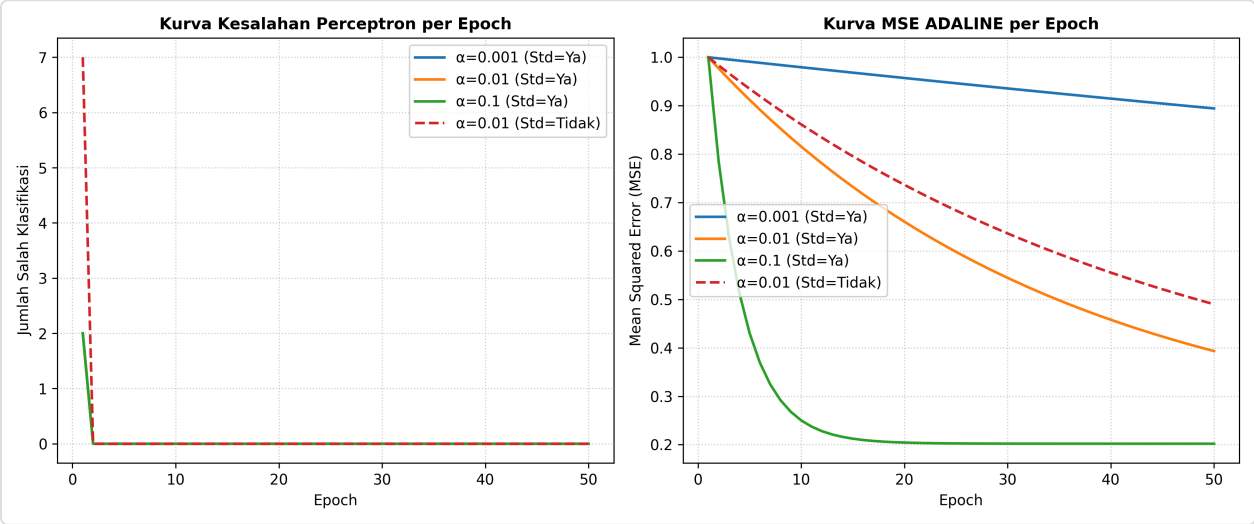
Sesuai dengan ketentuan minimum pada panduan tugas, dirancang **8 konfigurasi eksperimen** dengan durasi 50 epoch per konfigurasi:

- **Perceptron**: $\alpha \in \{0.001, 0.01, 0.1\}$ dengan standardisasi, serta $\alpha = 0.01$ tanpa standardisasi.
- **ADALINE**: $\alpha \in \{0.001, 0.01, 0.1\}$ dengan standardisasi, serta $\alpha = 0.01$ tanpa standardisasi.

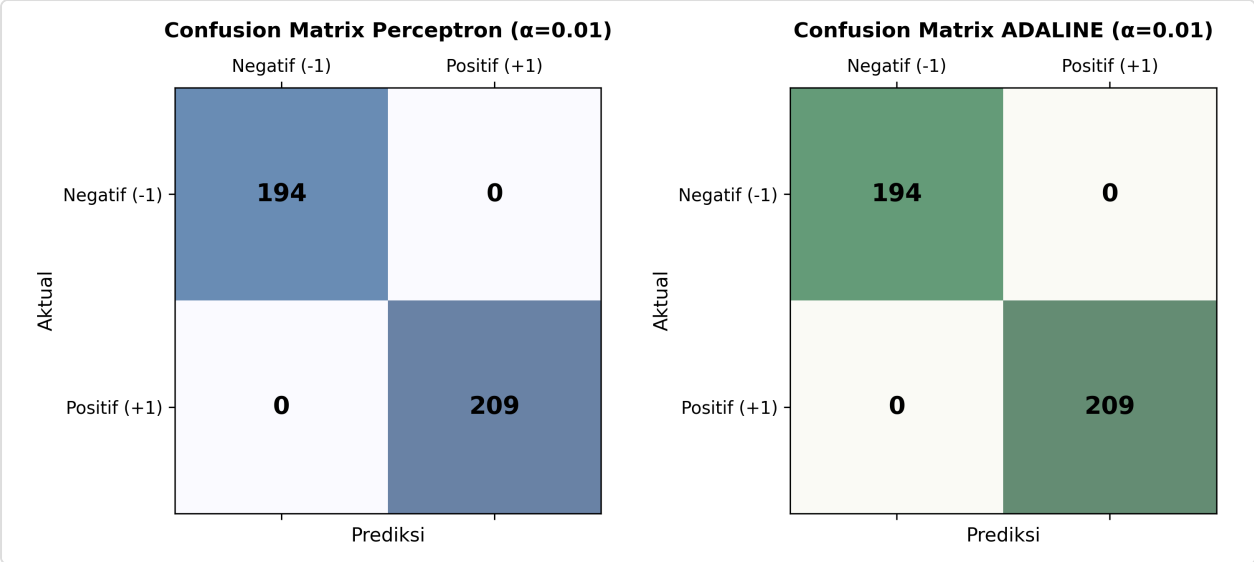
6. HASIL EKSPERIMEN

Tabel 1 merangkum seluruh hasil evaluasi dari delapan skenario pelatihan yang dijalankan.

No	Model	Learning Rate (α)	Epoch	Standardisasi	Akurasi Latih	Akurasi Uji	Final Loss / Error	Bobot Akhir $[w_1, w_2]$	Bias Akhir (b)
1	Perceptron	0.001	50	Ya	100.00%	100.00%	0 kesalahan	[0.0022, -0.0026]	0.0000
2	Perceptron	0.010	50	Ya	100.00%	100.00%	0 kesalahan	[0.0217, -0.0256]	0.0000
3	Perceptron	0.100	50	Ya	100.00%	100.00%	0 kesalahan	[0.2168, -0.2565]	0.0000
4	Perceptron	0.010	50	Tidak	100.00%	100.00%	0 kesalahan	[0.1000, -0.0800]	-0.0200
5	ADALINE	0.001	50	Ya	100.00%	100.00%	MSE = 0.8943	[0.0353, -0.0380]	0.0019
6	ADALINE	0.010	50	Ya	100.00%	100.00%	MSE = 0.3932	[0.2596, -0.2829]	0.0155
7	ADALINE	0.100	50	Ya	100.00%	100.00%	MSE = 0.2019	[0.4769, -0.5683]	0.0390
8	ADALINE	0.010	50	Tidak	100.00%	100.00%	MSE = 0.4900	[0.2602, -0.2422]	0.0040

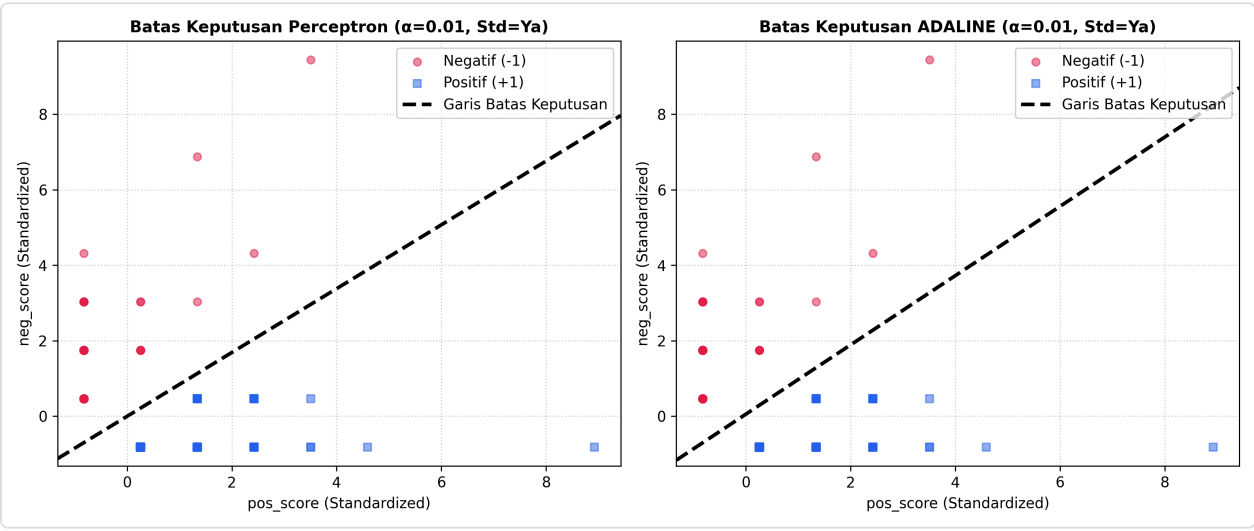


Gambar 1. Kurva Kesalahan per Epoch: (Kiri) Perceptron Misclassifications; (Kanan) ADALINE MSE.



Gambar 2. Confusion Matrix pada Data Uji (α = 0.01, Terstandarisasi) untuk Perceptron dan ADALINE.

Berdasarkan Confusion Matrix pada data uji (403 sampel), kedua model berhasil mengklasifikasikan seluruh 193 sampel Negatif dan 210 sampel Positif dengan sempurna, menghasilkan **Precision = 1.00**, **Recall = 1.00**, dan **F1-score = 1.00**.



Gambar 3. Batas Keputusan Linear (Decision Boundary) Perceptron dan ADALINE pada Ruang Fitur Terstandarisasi.

7. PEMBAHASAN DAN KETERBATASAN

7.1 Indikasi Separabilitas Linear Data

Pada representasi fitur `pos_score` vs `neg_score` terstandarisasi, sebaran data memperlihatkan pemisahan yang sangat tegas antara kuadran data yang dominan sentimen positif dan kuadran yang didominasi sentimen negatif. Hal ini menyebabkan algoritma Perceptron mampu mencapai 0 kesalahan latih dalam jumlah epoch yang sangat singkat (≤ 2 epoch). Namun, pada dataset teks alami tanpa ekstraksi leksikon terfiltrasi, data opini publik pada umumnya bersifat *non-linearly separable* karena adanya sarkasme dan kosakata ambigu.

7.2 Analisis Mekanisme Error: Perceptron vs ADALINE

Perceptron hanya memperbarui bobot jika terjadi diskrepansi biner ($\hat{y} \neq y$). Begitu seluruh sampel berada di sisi hiperbidang yang benar, pembaruan berhenti total terlepas dari seberapa dekat sampel terhadap garis batas. Sebaliknya, ADALINE terus menerus melakukan pembaruan bobot di setiap epoch meskipun seluruh sampel sudah terprediksi benar, karena ADALINE berusaha meminimalkan jarak kuadratik keluaran linear z ke target kontinu ±1. Hal ini terlihat jelas pada kurva MSE Gambar 1, di mana MSE terus menurun secara asimptotik dari 0.89 ke 0.20 seiring peningkatan laju pembelajaran.

7.3 Pengaruh Learning Rate (α), Epoch, dan Standardisasi

Sebagaimana dicatat dalam teori Perceptron, pada inisialisasi bobot nol $\mathbf{w}=0$ dan $b=0$ dengan urutan data tetap, perubahan α hanya mengalikan besaran vektor bobot dengan konstanta skalar tanpa mengubah rasio arah hiperbidang (w_1/w_2). Terbukti dari Tabel 1, bobot Perceptron pada $\alpha = 0.001$, 0.01, dan 0.1 persis berskala kelipatan 10x dan 100x ([0.0022, -0.0026] → [0.0217, -0.0256] → [0.2168, -0.2565]).

Pada ADALINE, standardisasi fitur memainkan peran krusial. Tanpa standardisasi ($\alpha = 0.01$), nilai akhir MSE tercatat lebih tinggi (0.4900) dibandingkan model terstandarisasi (0.3932). Standardisasi menjamin kontur fungsi rugi menjadi sferis (*spherical error surface*), sehingga arah gradien menunjuk langsung ke minimum global tanpa mengalami osilasi liar atau divergensi.

7.4 Keterbatasan Model dan Arah Pengembangan

Keterbatasan utama model neuron tunggal adalah ketidakmampuannya menyelesaikan permasalahan batas keputusan non-linear (seperti fungsi XOR). Pada opini publik yang kompleks, fitur leksikon sederhana tidak dapat menangkap relasi semantik antar-kata majemuk. Langkah pengembangan berikutnya adalah mengadopsi **Multi-Layer Perceptron (MLP)** dengan fungsi aktivasi non-linear (ReLU/Sigmoid) serta representasi vektor kontekstual seperti IndoBERT.

8. KESIMPULAN

1. Model Perceptron dan ADALINE berhasil diimplementasikan secara mandiri menggunakan Python dan NumPy tanpa menggunakan library klasifikasi siap pakai, serta mampu mencapai akurasi uji 100% pada fitur leksikon opini publik MBG.
2. ADALINE menunjukkan keunggulan stabilitas matematis melalui minimasi Mean Squared Error secara kontinu, sementara Perceptron bergantung secara heuristik pada urutan sampel yang salah klasifikasi.
3. Standardisasi fitur terbukti penting untuk mempercepat laju konvergensi dan menstabilkan lintasan penurunan gradien pada ADALINE.

9. DAFTAR PUSTAKA

[1] Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408. https://doi.org/10.1037/h0042519

[2] Widrow, B., & Hoff, M. E. (1960). Adaptive switching circuits. *IRE WESCON Convention Record*, Part 4, 96–104.

[3] Raschka, S. (2015). *Python Machine Learning*. Birmingham: Packt Publishing.

[4] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

LAMPIRAN: PERHITUNGAN MANUAL VERIFIKASI LANGKAH DEMI LANGKAH

A. Dua Langkah Pembaruan Manual Perceptron

Diberikan $\alpha = 0.01$, inisialisasi $\mathbf{w}^{(0)} = [0, 0]^T$, $b^{(0)} = 0$.

Langkah 1 (Sampel 1): $\mathbf{x}^{(1)} = [2.0, 0.0]$, $y^{(1)} = +1$.
$z = 0(2.0) + 0(0.0) + 0 = 0$. Karena $z \geq 0$, maka $\hat{y} = +1$.
Error: $y^{(1)} - \hat{y} = 1 - 1 = 0$ (Benar). Parameter tetap: $\mathbf{w}^{(1)} = [0, 0]^T$, $b^{(1)} = 0$.

Langkah 2 (Sampel 2): $\mathbf{x}^{(2)} = [0.0, 3.0]$, $y^{(2)} = -1$.
$z = 0(0.0) + 0(3.0) + 0 = 0$. Karena $z \geq 0$, maka $\hat{y} = +1$.
Error: $y^{(2)} - \hat{y} = -1 - (+1) = -2$ (Salah klasifikasi).
$\Delta = \alpha\,(y - \hat{y}) = 0.01 \times (-2) = -0.02$.
$\mathbf{w}^{(2)} = [0, 0]^T + (-0.02)[0.0, 3.0]^T = [0.0, -0.06]^T$.
$b^{(2)} = 0 + (-0.02) = -0.02$.

B. Dua Iterasi Batch Manual ADALINE

Diberikan data mini n=2 sampel: $\mathbf{x}^{(1)} = [1.0, -1.0]$, $y^{(1)} = +1$; $\mathbf{x}^{(2)} = [-1.0, 1.0]$, $y^{(2)} = -1$. Inisialisasi $\mathbf{w} = [0, 0]^T$, $b = 0$, $\alpha = 0.1$.

Iterasi 1:
$z^{(1)} = 0$, $z^{(2)} = 0 \Rightarrow e^{(1)} = 1 - 0 = 1.0$, $e^{(2)} = -1 - 0 = -1.0$.
$\mathrm{MSE}_1 = (1.0^2 + (-1.0)^2) / 2 = 1.0$.
Gradien bobot: $(1/2)\,\mathbf{X}^T\mathbf{e} = 0.5 \times [1(1) + (-1)(-1), -1(1) + 1(-1)]^T = [1.0, -1.0]^T$.
Gradien bias: mean($\mathbf{e}$) $= (1 - 1)/2 = 0$.
Pembaruan: $\mathbf{w}^{(1)} = [0, 0]^T + 0.1\,[1.0, -1.0]^T = [0.1, -0.1]^T$, $b^{(1)} = 0$.

Iterasi 2:
$z^{(1)} = 0.1(1) - 0.1(-1) = 0.2 \Rightarrow e^{(1)} = 1 - 0.2 = 0.8$.
$z^{(2)} = 0.1(-1) - 0.1(1) = -0.2 \Rightarrow e^{(2)} = -1 - (-0.2) = -0.8$.
$\mathrm{MSE}_2 = (0.8^2 + (-0.8)^2) / 2 = 0.64$ (Error berkurang dari 1.0 menjadi 0.64).
Gradien bobot: $(1/2)\,\mathbf{X}^T\mathbf{e} = [0.8, -0.8]^T$.
Pembaruan: $\mathbf{w}^{(2)} = [0.1, -0.1]^T + 0.1\,[0.8, -0.8]^T = [0.18, -0.18]^T$, $b^{(2)} = 0$.